Wisconsin Breast Cancer Veri Kümesi Üzerinde Kümeleme Analizi

Hazırlayan : Özhan YANA [2023280132]

1. Giriş

Bu çalışmada, Wisconsin Breast Cancer (WDBC) veri kümesi temel alınarak denetimsiz öğrenme yaklaşımıyla kümeleme analizi gerçekleştirilmiştir. Amaç, veri içerisindeki örnekleri benzer özelliklerine göre gruplandırmak ve elde edilen kümelerin yapısını incelemektir. Veri kümesi, kanser teşhisiyle ilişkili çeşitli sayısal özellikleri içermekte olup, bu nedenle biyomedikal alanında sıkça kullanılan bir örnek olarak kabul edilir.

2. Veri Kümesi ve Ön İşleme

Analizde kullanılan veri kümesi 'wdbc.data' dosyasında yer almakta olup, 30 adet sayısal özellik içermektedir. Veride eksik değer bulunmadığı doğrulanmıştır. Fakat her bir özelliğin farklı ölçeklerde olması, veriyi doğrudan kümeleme için uygun hale getirmemektedir. Bu nedenle tüm özellikler StandardScaler yöntemiyle ölçeklendirilmiştir. Bu işlem, her özelliğin ortalamasını sıfır ve varyansını bir hale getirerek, algoritmanın özellikler arasındaki farklı büyüklüklerden etkilenmemesini sağlar.

3. Kullanılan Yöntem

Kümeleme işlemi için K-ortalamalar (K-Means) algoritması tercih edilmiştir. Bu algoritma, gözlemleri k sayıda kümeye ayırarak her kümenin merkezini belirler. K değeri belirlenirken farklı denemeler yapılmış ve uygun küme sayısı, dirsek (elbow) yöntemiyle belirlenmiştir. Ayrıca, kümelerin ayrışma düzeyini değerlendirmek için Silhouette skoru hesaplanmıştır. Bu metrik, kümeler arası uzaklık ve küme içi benzerlik arasındaki ilişkiyi ölçerek kümelenmenin başarısını değerlendirir.

4. Bulgular

Kümeleme sonuçları incelendiğinde, verilerin iki temel grup etrafında toplandığı görülmüştür. Bu grupların, veri kümesindeki benign (iyi huylu) ve malignant (kötü huylu) örneklerle genel olarak örtüştüğü gözlenmiştir. Ancak denetimsiz yöntemlerin doğası gereği, bu uyumun tam olarak birebir olması beklenmemektedir. Verinin yüksek boyutlu yapısı ve bazı özelliklerin yüksek korelasyonu, sonuçları etkileyen faktörler arasında yer almaktadır.

5. Tartışma ve Sonuç

Bu çalışmada, WDBC veri kümesi üzerinde yapılan kümeleme analizi, denetimsiz öğrenme yöntemlerinin biyomedikal veri kümelerinde uygulanabilirliğini göstermektedir. Sonuçlar, önişleme adımlarının ve uygun küme sayısının belirlenmesinin analiz kalitesine önemli ölçüde katkı sağladığını ortaya koymaktadır. İlerleyen çalışmalarda, farklı kümeleme yöntemleri (örneğin DBSCAN veya Hiyerarşik Kümeleme) ve boyut indirgeme teknikleri (PCA gibi) kullanılarak sonuçlar karşılaştırılabilir.

6. Çıktılar

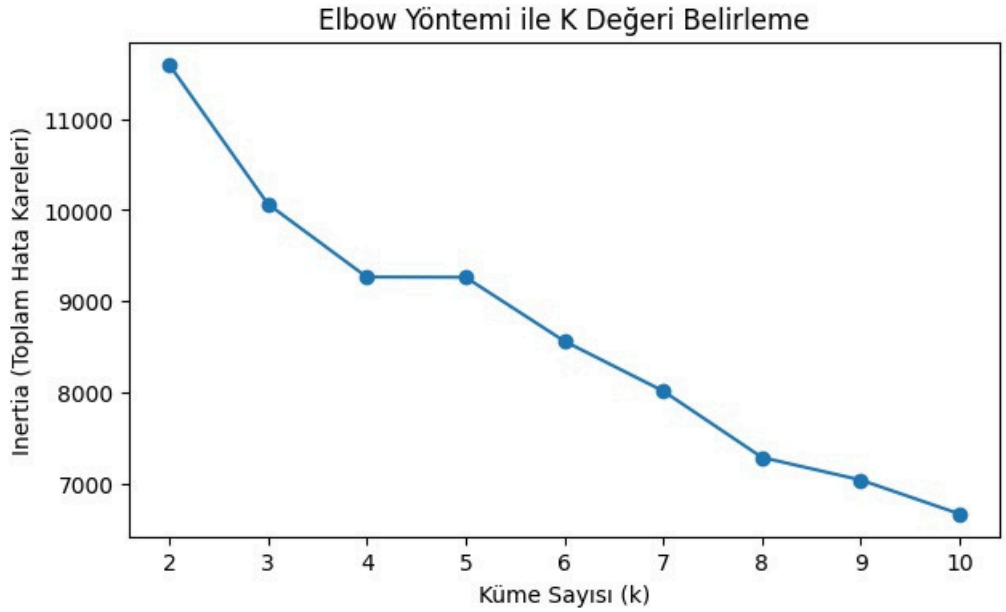

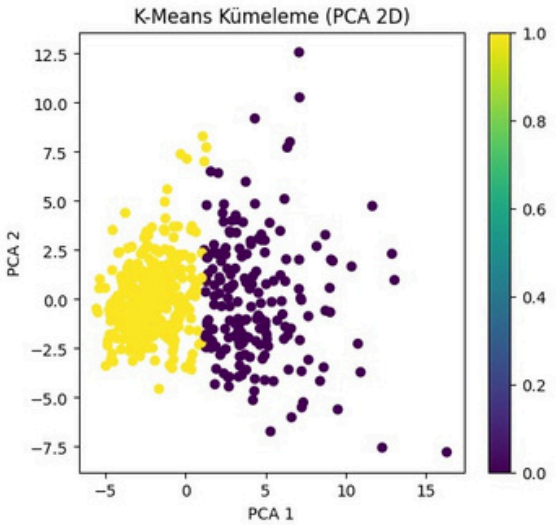

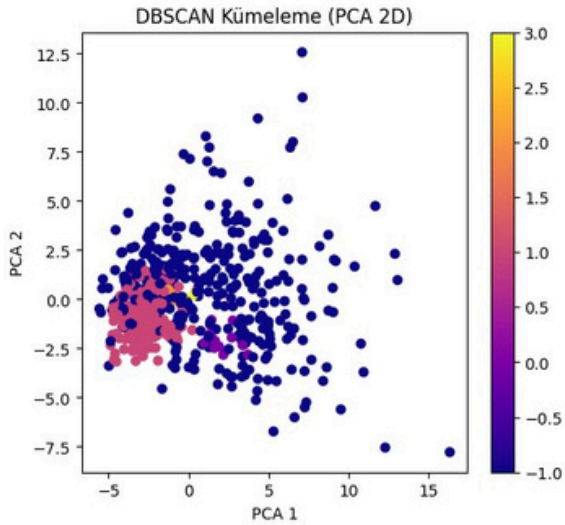

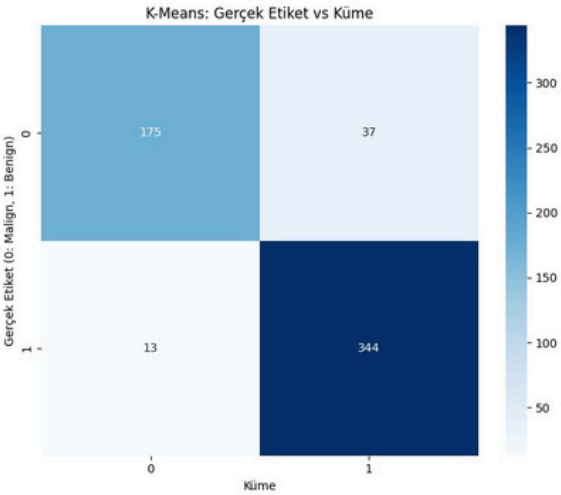

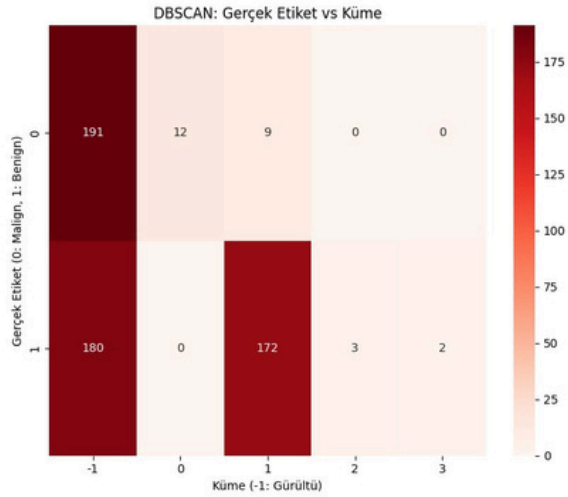

7. Kaynakça

1. UCI Machine Learning Repository – Wisconsin Breast Cancer (Diagnostic) Data Set
2. J. Han, M. Kamber, J. Pei. ‘Data Mining: Concepts and Techniques.’ 4th Edition, 2022.
3. Scikit-learn Documentation, https://scikit-learn.org/